



AGH

**AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W
KRAKOWIE**

**WYDZIAŁ ELEKTROTECHNIKI, AUTOMATYKI,
INFORMATYKI I INŻYNIERII BIOMEDYCZNEJ**

KATEDRA AUTOMATYKI I ROBOTYKI

Praca dyplomowa magisterska

*Kognitywny system eksploracji środowiska przez
inteligentnego agenta z wykorzystaniem uczenia
motywowanego.*

*Cognitive system of environment exploration by an
intelligent agent using motivated learning*

Autor:

Bartłomiej Styczeń

Kierunek studiów:

Automatyka i robotyka

Opiekun pracy:

dr hab. Adrian Horzyk, prof. AGH

Kraków, 2020

Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystycznego wykonania albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, wideogram lub nadanie.”, a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.): „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej «sądem koleżeńskim».”, oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobiście i samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.

*Serdecznie dziękuję ...tu ciąg dalszych
podziękowań np. dla promotora, żony, są-
siada itp.*

Spis treści

1. Wprowadzenie	7
1.1. Cele pracy	8
1.2. Zawartość pracy	9
2. Uczenie motywowane	11
2.1. Definicje związane z projektowaniem ucieleśnionej inteligencji	12
2.2. Inteligencja	12
2.3. Projektowanie ucieleśnionej inteligencji	13
2.4. Ból jako motywacja	14
2.5. Tworzenie celów w uczeniu motywowanym	16
2.6. Podstawowy element systemu tworzenia celów	17
3. Uczenie ze wzmocnieniem	21
4. Uczenie motywowane i ze wzmocnieniem – porównanie	23
5. Środowisko symulacyjne	25

1. Wprowadzenie

Od początku pierwszych urządzeń elektronicznych, a szczególnie zaprojektowaniu pierwszych komputerów, które mogły wykonywać pewne zbiory instrukcji, naukowcy zastanawiali się jak wykorzystać te moce obliczeniowe. Próbowano zdefiniować pojęcie inteligencji. I tak w roku 1955 termin *sztuczna inteligencja* został wprowadzony jako dyscyplina naukowa. Natomiast w roku 1950 matematyk Alan Turing opracował test nazwany jego nazwiskiem, którego celem jest sprawdzenie czy maszyna, która posiada inteligencję równą lub przewyższającą człowieka.

Test został wprowadzony w artykule [1], w którym Turing zaproponował zastąpienie pytania: *Can machines think?* (ang. *Czy maszyny myślą?*) pewną formą testu. Polega on na prowadzeniu rozmowy przez 2 osoby i jedną maszynę. Zadaniem jednego człowieka i maszyny jest przekonanie sędziego, że są one człowiekiem. Jeżeli sędzia nie jest w stanie zdecydować, oznacza to, że maszyna zdaje test. Ostatecznie pytanie, które zadawał Turing na początku artykułu zostaje zmienione na: *Can machines do what we (as thinking entities) can do?* (ang. *Czy maszyny umieją robić to, co myślące istoty?*).

Temat inteligencji był coraz bardziej popularny, ale po kilku latach badań, nie osiągnęto rezultatów. Nastąpiła tzw. zima dla AI (ang. *AI winter*). W trakcie kilku dziesięcioleci nie prowadzono wielu badań w zakresie sztucznej inteligencji. Trwało to do początku lat dziewięćdziesiątych, kiedy to w roku 1998 francuski informatyk Yann LeCun wydał artykuł [2] opisujący konwolucyjne sieci neuronowe, które uczyły bezpośrednio z obrazów, a nie z wcześniej zaprojektowanych cech. Był to początek przełomu w procesie uczenia sztucznych sieci neuronowych, ponieważ pierwszy raz można było przeprowadzić w pełni automatyczne uczenie sieci neuronowej.

Kolejnym przełomem w dziedzinie sztucznej inteligencji była praca Alexa Krizhevskiego, Ilyi Sutskevera i Geoffreya E. Hintonu [3]. Ich przełomowa implementacja architektury sieci konwolucyjnej na kartach graficznych umożliwiła stworzenie głębokiej (jak na rok 2012) sieci, która wygrała konkurs ImageNet [4]. Od tego roku tematyka sztucznych sieci neuronowych,

a w szczególności konwolucyjnych sieci neuronowych. Postęp technologiczny w architekturach kart graficznych umożliwił tworzenie coraz większych sieci, które dawały coraz lepsze rezultaty. Powrót do algorytmów uczenia ze wzmocnieniem (ang. *reinforcement learning*) sprawił, że powróciła chęć rozwijania sztucznej inteligencji, a nawet próby regulacji prawnej tych rozwiązań.

Szczególną uwagę należy zwrócić na uczenie ze wzmocnieniem, które przypomina po części silną sztuczną inteligencję (ang. *artificial general intelligence*). Agent mając niewiele informacji o środowisku jest w stanie nauczyć się skomplikowanych zadań bez wcześniejszej wiedzy. Popularnym przykładem jest AlphaGo, który został zaprojektowany przez naukowców z DeepMind do grania w grę Go [5].

Należy jednak pamiętać, że mimo świetnych wyników tych programów komputerowych, to daleko im od silnej sztucznej inteligencji. Są one przystosowane do rozwiązywania jednego problemu, w znanym środowisku. Jak środowisko zostanie zmienione, to wyniki nie są aż tak dobre. AlphaGo nie zacznie nagle autonomicznie sterować samochodem, ponieważ algorytm zna całkowicie inne środowisko. Można zauważyć brak przystosowania do zmieniającego się środowiska.

Jednym z podejść, aby rozwiązać problem dynamicznego środowiska jest umożliwienie agentowi samodzielne decydowanie jakie zadania musi on wykonać, aby rozwiązał główny problem. Uczenie motywowane (ang. *motivated learning*) odnosi się do tego problemu i umożliwia rozwiązywanie złożonych problemów w zmieniających się warunkach działania agenta.

Ta praca jest o uczeniu motywowanym przy eksploracji środowiska przez agenta, który w przypadku tej pracy dyplomowej będzie wykonywana na robocie mobilnym. Zastosowane zostanie środowisko symulacyjne umożliwiające sterowanie takim robotem, odczytywanie różnych parametrów środowiska otaczającego agenta, także tych, których sensory robota, np. kamera, czujniki odległości, nie umożliwiają do odczytania.

1.1. Cele pracy

Celem pracy było zbadanie skuteczności uczenia motywowanego przy eksploracji i poznawaniu wirtualnego środowiska przez inteligentnego agenta kognitywnego. Zakres pracy obejmował przygotowanie wirtualnego środowiska umożliwiającego testowanie zaimplementowanych rozwiązań. Następnie inteligentny agent miał za zadanie poznawanie środowiska i tworzenie nowych skojarzeń i wiedzy poprawiających jego umiejętności oraz stopniowo rozbudowujących hierarchię jego potrzeb i możliwości.

TODO

W ramach pracy należało sprawdzić i porównać skuteczność nowych rozwiązań z zakresu uczenia motywowanego z innymi podejściami, np. uczeniem ze wzmocnieniem.

TODO

Pierwszym etapem był przegląd literatury związanej z tematem uczenia motywowanego oraz uczenia ze wzmocnieniem, którego celem było zgłębienie wiedzy na ten temat w celu zrozumienia różnic i możliwych ograniczeń powyższych rozwiązań.

Bardzo ważnym etapem był wybór środowiska symulacyjnego, aby móc szybko testować zaimplementowane rozwiązania. Takie podejście umożliwia bezpieczne sprawdzenie algorytmów, w takim środowisku wystarczy jeden przycisk, aby przerwać całe zadanie bez zagrożenia dla ludzi w środowisku oraz samego robota. Ważne, aby wybrane środowisko umożliwiło dużą ingerencję w środowisko. Tworzenie dynamicznego świata jest podstawą, aby można było testować skuteczność algorytmów uczenia motywowanego.

Większość algorytmów zaimplementowano w językach C++/Python, tak aby wysoka logika mogła być szybko prototypowana w języku jakim jest Python, natomiast wszelkie obliczenia, które wymagają dużej wydajności zostały zaimplementowane w języku C++.

Istotnym aspektem tej pracy dyplomowej jest analiza porównawcza z innymi znanymi i ugruntowanymi algorytmami do eksploracji środowiska, np. SLAM (ang. *simultaneous localization and mapping*). Porównanie osiągnięć agenta wykorzystującego algorytmy uczenia motywowanego z podobnym agentem korzystającym z innych podejść umożliwi sprawdzenie czy umożliwienie tworzenia własnych wewnętrznych celów sprawia, że agent dostosowuje się do zmiennego środowiska.

1.2. Zawartość pracy

Ta część będzie napisana jak cała reszta pracy zostanie ukończona. . .

2. Uczenie motywowane

Człowiek od momentu, kiedy jest w stanie poznawać swoje środowisko, w którym się znajduje ma ochotę eksplorować na swoje możliwości. Małe dzieci, które nie umieją jeszcze chodzić albo raczkować, mogą tworzyć skojarzenia pomiędzy różnymi czynnikami. Jednym z przykładów może być nawet karmienie takiego dziecka małą butelką i poprzez umożliwianie mu trzymania tej butelki samodzielnie, małe dziecko będzie w stanie po pewnym czasie utworzyć skojarzenie, że jeżeli będzie trzymało mocno butelkę i w odpowiedniej pozycji, to będzie mogło zjeść w razie głodu.

Eksploracja środowiska i swobodne poznawanie go, umożliwia tworzenie połączeń asocjacji pomiędzy pewnymi obserwacjami, akcjami jakie wykonaliśmy na nich oraz rezultatów jakie zostały otrzymane w wyniku takich a nie innych akcji. Innym przykładem u małego człowieka jest to, że niepilnowane młode dziecko może dotknąć czegoś gorącego i się oparzyć, mimo, że rodzice zabronili tego. Dopiero poczucie fizycznego bólu sprawi, że dziecko będzie dobrze pamiętało, żeby więcej tego nie robić. Dlatego też człowiek często uczy się na własnych błędach najlepiej, kiedy sam czegoś doświadczy.

Kluczowe dla uczenia motywowanego (ang. *motivated learning*) jest pojęcie motywacji w ucieleśnionej inteligencji (ang. *motivation in embodied intelligence*). Inteligencja ucieleśniona jest obliczeniowym podejściem do projektowania i rozumienia inteligentnego zachowania u ucieleśnionych agentów poprzez wzięcie pod uwagę ścisłego powiązania między agentem, a jego otoczeniem. Należy brać pod uwagę jego ograniczenia tj. ograniczenia własnego ciała (ograniczenia mechaniczne i/lub elektryczne robota), systemu percepcyjnego (systemy wizyjne i ich sprzętowe ograniczenia) oraz motoryczne. Jedną z najbardziej wpływowych postaci w procesie projektowania ucieleśnionej inteligencji jako metodologii był Rodney Brooks. Zaproponował on tworzenie inteligentnych maszyn poprzez interakcję ze środowiskiem napędzane przez percepcję i akcję niż przez konkretnie wyspecjalizowany algorytm.

W dzisiejszych czasach badania w zakresie sztucznej inteligencji są kojarzone z wyspecjalizowanym rozwiązywaniem problemów tj. reprezentacja wiedzy, zrozumienie języka naturalnego czy oglądanie sceny czy odpowiadanie na pytania. Wszystkie te zagadnienia są bardzo ciekawe

i sprawiają, że wiele problemów zostaje rozwiązywane przez komputery. Jednak nie ma w nich systemu, który spaja wszystkie te zagadnienia w jeden system, który mógłby być określaną silną inteligencją".

2.1. Definicje związane z projektowaniem ucieleśnionej inteligencji

W celu projektowania maszyn ucieleśnionej inteligencji zostały zdefiniowane pewne zasady i założenia. Pierwszym z nich było to, że agent rozwija się w zmieniającym środowisku, które może manipulować i postrzegać korzystając z dostępnych sensorów. Nie istnieje potrzeba tworzenia modelu środowiska, ponieważ ono się może zmieniać.

Dodatkowe reguły projektowania zostały zawarte w [6]:

1. Reguła taniego projektu i nadmiarowości – projekt maszyny powinien być prosty i jego projekt sprawiał, że funkcjonalności podzespołów nachodzą na siebie pozwalając na działanie maszyny w razie awarii jakiegoś podzespołu.
2. Reguła równoległych, luźno związanych procesów – ta reguła wymusza na maszynie to, że inteligencja pojawia się przez interakcję niskopoziomowych procesów np. sterowania ramionami ze środowiskiem.
3. Reguła wartości – reguła ta może wymuszać, aby maszyna robiła, to co jest dobre dla niej. Umożliwia ona sugerowanie maszynie, co powinna zrobić w danej sytuacji (agenty uczenia ze wzmocnieniem uczą się korzystając m.in. z tej reguły)

2.2. Inteligencja

Do dzisiaj nie ma dokładnej definicji inteligencji. Jest wiele interpretacji, a jednocześnie należy mieć na uwadze, aby nie mylić inteligencji ze złożonym zachowaniem. To bardzo ważne, ponieważ możemy wziąć pewien algorytm, np. szukania najkrótszej ścieżki w grafie, która ogółem jest złożonym problemem, który składa się ze skończonej liczby kroków. Zdecydowanie nie można stwierdzić, że ten algorytm jest inteligentny. To tylko pewien zbiór prostych czynności, które rozwiązują konkretny problem i użyte do czegoś innego (można tak nazwać zmieniające się środowisko), na pewno nie da dobrych rezultatów.

Opisy inteligencji skupiają się na opisie właściwości umysłu, niż samym umyśle. W swojej pracy [7] John Stewart zdefiniował systemy kognitywne jako:

Definicja: System jest kognitywny wtedy i tylko wtedy, gdy wejścia z sensorów powodują akcje w konkretny sposób, tak aby spełnić wymagania do przeżycia w środowisku.

Definicja: Ucieleśniona inteligencja (ang. *embodied intelligence* EI) jest zdefiniowana jako mechanizm, który uczy się jak przetrwać we wrogim środowisku (wrogię można także określić jako zmieniające się).

Ta druga definicja odnosi się do wszystkich form ucieleśnionej inteligencji: biologicznej, mechanicznej czy wirtualnych agentów. Wynika z tego, że agent EI wchodzi w interakcje ze środowiskiem i postrzega wprowadzone zmiany poprzez sensory. Agent musi się nauczyć jak przetrwać w środowisku. Natomiast wrogość środowiska może być określana na różne sposoby. Może to być jego ciągła zmienność, czy mała dostępność surowców potrzebnych agentowi przetrwania. Ważne jest to, że ta wrogość jest stała. Przykładowo, poziom naładowania baterii jest stałym zagrożeniem dla agenta. Jeżeli poziom naładowania będzie się zmniejszał, to dyskomfort wywoływany przez sensor odpowiedzialny za pomiar baterii będzie rósł.

Kolejnym ważnym elementem definicji ucieleśnionej inteligencji jest aspekt uczenia. Jeżeli agent wie jak przetrwać we wrogim środowisku, ale nie wie jak się nauczyć nowych umiejętności, nie jest inteligentny. Przykładowo, algorytm, która zajmuje się sterowaniem jakiegoś procesu technologicznego nie jest inteligentny, ponieważ nie będzie w stanie nauczyć się sterować samochodem. W zamierzeniu jego zadaniem było regulowanie wartości zadanej konkretnego procesu technologicznego.

Należy zwrócić uwagę, że EI odróżnia wiedzę od inteligencji. Wiedza może być w pewien sposób zintegrowana z agentem w trakcie jego projektowania, np. jako zbiór pewnych reguł zachowania. Natomiast inteligencja sprawia, że ta wiedza może być użyta do tworzenia nowych umiejętności i zarządzania nimi w sposób zorganizowany i koherentny.

2.3. Projektowanie ucieleśnionej inteligencji

Uczenie jest aktywnym procesem. Informacje o otoczeniu EI zdobywa poprzez koordynację pary sensor – motor. Uczenie się, które akcje są pożądane, a które nie, sprawiają, że agent uczący jest lepiej przystosowany do wrogiego środowiska. Można odróżnić co najmniej dwa sposoby na adaptowanie do zmiennego środowiska [8]:

1. ewolucyjne – naturalna selekcja agentów (gatunków zwierząt), które są najlepiej przystosowane lub rozwój nowych umiejętności np. pocenie się, aby utrzymać odpowiednią temperaturę,
2. kognitywne – poprzez uczenie, używając pamięci i asocjacji, stosując rozpoznawanie schematów, budowanie reprezentacji i implementowanie celów.

Schematy na wielu poziomach abstrakcji są uczone i zapamiętywane przez agenta. Pewne abstrakcyjne reprezentacje są budowane aby reprezentować akcje i umiejętności. Cała struktura wzorów i relacji pomiędzy nimi jest reprezentowana w pewnej postaci w pamięci, która jest asocjacyjna i epizodyczna. Ten system jest rozproszony, nadmiarowy i równoległy a dodatkowo krótko i długoterminowy. Cały ten system łączy się ze sobą i wchodzi w interakcję w czasie rzeczywistym.

Krytycznym aspektem rozwoju umysłu człowieka jest samoorganizacja. Dzięki niej neurony mogą szybko tworzyć nowe reprezentacje zapamiętanych schematów, uczyć się jak wchodzić w interakcję z otoczeniem oraz budować oczekiwania związane z przyszłymi wydarzeniami, czyli umiejętność prognozowania przyszłych wydarzeń na podstawie aktualnego stanu oraz tego, co stało się w przeszłości.

Agent uczenia motywowanego dzieli wspólne właściwości ze specjalnym typem agenta racjonalnego (ang. *rational software agent*) znanego jako agenta przekonań – pragnień – intencji (ang. *belief – desire – intention*). To pewien z modeli tworzenia oprogramowania, który umożliwia rozdzielenie funkcjonalności od siebie. Ten model skupia się na planowaniu i sposobie wykonania pewnych zadań. Cechy wspólne z agentem uczenia motywowanego to tworzenie reprezentacji poznanego środowiska, pragnienia to motywacje dla agenta motywowanego. Różnicą jest sposób implementacji reprezentacji wiedzy. Dla agenta uczenia motywowanego nie ma konkretnego sposobu implementacji, ponieważ widza ta jest reprezentowana przez struktury sieci neuronowych a tym samym wszelkie plany, co do wykonywanych akcji muszą być pochodzą z aktywacji neuronów w sieci neuronowej.

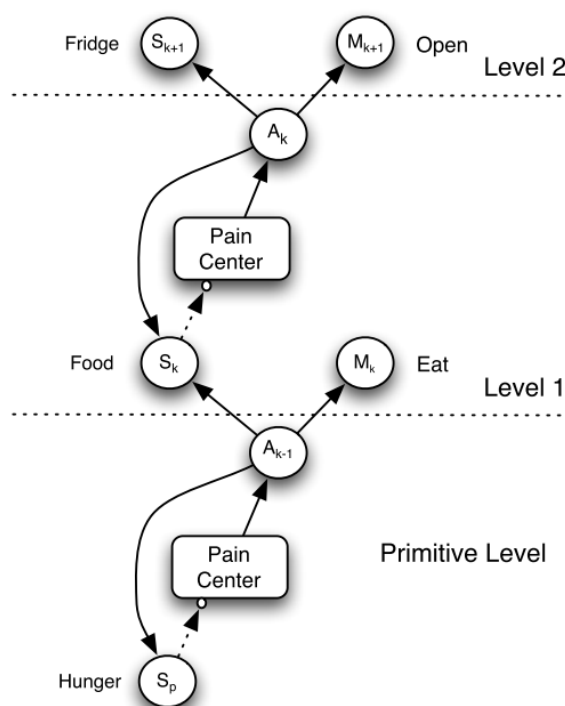
2.4. Ból jako motywacja

Zadaniem każdej maszyny jest wykonywanie pewnych z góry określonych zadań. Pytaniem jest, co może być motywujące, aby dana maszyna/program wykonywały go w sposób perfekcyjny. Dla pewnych grup algorytmów można zdefiniować z góry określoną funkcję kosztu, którą w sposób iteracyjny usprawnia działanie danego algorytmu. Jednakże takie podejście daje bardzo mało możliwości do generalizowania zdobytych umiejętności na nowe potrzeby, np. zmiennego środowiska.

Aby odpowiedzieć na pytanie, co może motywować maszyny do ulepszania swoich możliwości w sposób bardziej zgeneralizowany, można zastanowić się, co motywuje ludzi do rozwijania swoich umiejętności. Próba odpowiedzi na to pytanie podjął się psycholog Csíkszentmihályi w książce opisującej teorię przepływu [9]. W tej teorii opisano, że ludzie otrzymują wewnętrzne nagrody za wszelkie aktywności, które są trochę ponad ich aktualny poziom rozwoju.

Starzyk w pracy [8] sugeruje, że to wrogość środowiska, które jest ujęte w definicji agenta ucieleśnionej inteligencji (EI) jest najbardziej efektywnym czynnikiem motywującym do uczenia. Ma to odniesienie do ludzkiego sposobu uczenia. Podstawowym bólem może być ciekawość. To ona sprawia, że chcemy poznawać nowe rzeczy. Dla małego dziecka taka ciekawość może wywołać ból fizyczny, kiedy z ciekawości oparzy się dotykając czegoś gorącego. Ale ten ból sprawi, że w przyszłości będzie wiedziało jak postępować, aby nie zwiększać tego bólu.

Według Starzyka bóle prymitywne są bezpośrednio związane z bodźcami odbieranymi przez sensory maszyny. Natomiast definiuje on bóle abstrakcyjne (ang. *abstract pains*). Pojawiają się one, kiedy agent nie jest w stanie wykonać akcji, która zmniejszy wartość bólu prymitywnego. W ten sposób mogą się tworzyć struktury grafowe opisujące relacje pomiędzy różnymi bólami. Co ważne, bóle abstrakcyjne nie są stymulowane przez sensor wartości fizycznej, np. niski poziom naładowania baterii dla robota. 2.1.



Rys. 2.1. Tworzenie sygnałów abstrakcyjnych bóli. Źródło: [10]

Bóle tworzą hierarchię wszerz i włąb, tworząc struktury grafowe. W takich strukturach teoretycznie mogą pojawiać się zamknięte ścieżki, np. brak jedzenia może sprawić, żeby kupić więcej jedzenia, a do tego potrzebne są pieniądze, które można zdobyć sprzedając jedzenie. Należy wziąć pod uwagę takie sytuacje w procesie tworzenia całej architektury i sposobu uczenia maszyny.

2.5. Tworzenie celów w uczeniu motywowanym

Jednym z podstawowych źródeł tworzenia nowych celów jest wcześniej wspomniany ból. Najbardziej prymitywnym bólem u ludzi jest uczucie dyskomfortu, gdy czują głód. W maszynach można to odnieść do poziomu naładowania baterii w robocie i coraz niższy poziom sprawia, że ból związany z brakiem energii zwiększa się. Agent uczenia motywowanego musi się nauczyć jak ten ból zmniejszać, tak jak człowiek uczy się zdobywać jedzenie oraz jeść. Mimo, że wszelkie abstrakcyjne bóle, które wykształcają się w dalszym rozwoju, to te prymitywne umożliwiają realizację kolejnych zadań czy celów.

Dokładny opis algorytmu tworzenia celów został opisany w [11]

Algorytm tworzenia celów (ang. *goal creation system*)

1. Wybierz dominujący ból stosując regułę zwycięzca bierze wszystko (ang. *winner takes all*) spośród konkurujących ośrodków bólu.
 - Jeżeli żaden z bólów nie przekracza wcześniej zdefiniowanego progu, czekaj aż któryś z nich przekroczy ten próg.
2. Jako aktualny cel wybierz zmniejszenie dominującego bólu.
 - aktualny cel motywuje agenta do działania.
3. Wybierz wcześniej nauczoną akcję, która z najwyższym prawdopodobieństwem spełni aktualny cel.
 - Jeżeli nie ma żadnego, idź do punktu 6.
4. Sprawdź czy wybrana czynność może być wykonana w aktualnym środowisku. Jeśli nie, idź do punktu 3.
5. Wykonaj akcję.
 - Jeśli ta akcja *obniżyła* wartość dominującego bólu:
 - (a) Zwiększ wartości wag zależności pomiędzy aktualnym bólem a akcją jaka została wykonana i zwiększ wartości wag odpowiadających abstrakcyjnemu bólom powiązanego z tą akcją.
 - (b) Idź do punktu 1.
 - Jeśli ta akcja *nie obniżyła* wartości dominującego bólu.

(a) Zmniejsz wartości wag zależności pomiędzy aktualnym bólem a akcją jaka została wykonana i zmniejsz wartość wag odpowiadających abstrakcyjnemu bólowi powiązanego z tą akcją.

(b) Idź do punktu 3.

6. Wykonaj eksplorację przestrzeni akcji mającą na celu spełnienie celu.

– Jeśli nowa akcja *zmniejszyła* wartość dominującego bólu.

(a) Zwiększ wartości wag zależności pomiędzy aktualnym bólem a akcją jaka została wykonana i stwórz nowy abstrakcyjny ból związany z niemożliwością wykonania tej akcji.

(b) Idź do punktu 1.

– Jeśli nowa akcja *nie zmniejszyła* wartości dominującego bólu, idź do punktu 6.

Uczenie motywowane może być zastosowane wspólnie z uczeniem opartym na ciekawości (ang. *curiosity based learning*) – ciekawość poinformuje agenta o nowych odkryciach, podczas gdy uczenie motywowane skupi się na poszukiwaniu konkretnych celów, które nie są podane przez twórcę (tak jak w uczeniu ze wzmocnieniem).

2.6. Podstawowy element systemu tworzenia celów

Mechanizm budowania celów składa się z wielu, prostych elementów nazywanych jednostkami tworzenia celów (ang. *goal creation unit*). Składa się on głównie z trzech typów neuronów, które wchodzi ze sobą w interakcję. Są to:

- neurony odpowiadające za ból (ang. *pain center neurons*),
- neurony wzmacniające lub zmniejszające odczucie bólu (ang. *reinforcement neurotransmitter neurons*),
- neurony odpowiadające za motorykę (ang. *neurons in sensory and motor pathway*).

Schemat reprezentujący połączenia zawarto na rysunku 2.2.

Po wykonanej akcji, która zmniejszyła albo zwiększyła wartość odczuwanego bólu (wykrytego przez drugą grupę neuronów odpowiedzialną za detekcję bólu), generowany jest sygnał r (obliczony zgodnie z równaniem 2.1). Wykorzystywany jest to wzmacnienia lub osłabienia wag W_{MP} i W_{MS} zgodnie z równaniem 2.2

$$\begin{aligned} W_{MP} &= W_{MP} + r \cdot \beta^n \\ W_{MS} &= W_{MS} + r \cdot \beta^n \end{aligned} \tag{2.2}$$

gdzie:

- β – oznacza współczynnik uczenia, mniejszy od wartości 1,
- n – oznacza jak wiele razy dane połączenie było zmieniane.

Dodatkowo neuron odpowiedzialny za reprezentację obiektu, który był użyty do zmniejszenia bólu zostanie dodany z wagą W_{SP} w celu połączenia centrum detekcji bólu z neuronem sensorycznym. Ten neuron będzie uczony korzystając uczenia metodą Hebba.

Z kolei z drugiej strony, obiekt, którego zabrakło i stworzył on ból abstrakcyjny, staje się dostępny. Zostaje stworzony neuron reprezentujący połączenie neuronu odpowiedzialnego za motorykę z neuronem z brakującym obiektem z wagą W_{SM} .

Oba wymienione wcześniej połączone będą uczone metodą wzmacnienia. Oznacza to, że im mocniejsza zmiana poziomu bólu, tym mocniejsza korekta wartości tych wag.

3. Uczenie ze wzmocnieniem

Kilka słów o uczeniu ze wzmocnieniem...

4. Uczenie motywowane i ze wzmocnieniem – porównanie

Porównanie uczenia motywowanego do uczenia ze wzmocnieniem.

Tabela 4.1. Porównanie uczenia ze wzmocnieniem do uczenia motywowanego. Źródło: Motivated learning for computational intelligence

Uczenie ze wzmocnieniem	Uczenie motywowane
Jedna funkcja kosztu (określona zewnętrznie)	Wiele funkcji kosztu (tworzone przez agenta)
Mierzalne nagrody – może być zoptymalizowane	Wewnętrzne nagrody (niemierzalne) – nie może być zoptymalizowane
Możliwy do przewidzenia	Niemożliwy do przewidzenia
Zadania zdefiniowane przez badacza	Agent sam stwarza sobie cele
Maksymalizacja nagrody – potencjalnie niestabilne przy optymalizacji	Algorytm minimax – stabilne
Brak wewnętrznych motywacji i tworzenia celów	Wewnętrzne motywacje i tworzenie celów
Zawsze aktywne	Wykonuje akcje, kiedy jest taka potrzeba albo agent uzna to za konieczne
Wysiłek uczenia wzrasta wraz ze zwiększaniem skomplikowania środowiska	Agent uczy się lepiej w skomplikowanych środowiskach

5. Środowisko symulacyjne

Kilka słów o Gazebo...

Bibliografia

- [1] Alan Turing. „Computing Machinery and Intelligence”. W: *Mind* 236 (1950), s. 433–460. DOI: <https://doi.org/10.1093/mind/LIX.236.433>.
- [2] Yann LeCun. „Gradient-based learning applied to document recognition”. W: (1998). DOI: <http://yann.lecun.com/exdb/publis/pdf/lecun-99.pdf>.
- [3] Geoffrey E. Hinton Alex Krizhevsky Ilya Sutskever. „ImageNet Classification with Deep Convolutional Neural Networks”. W: (2012). DOI: <https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf>.
- [4] Stanford Vision Lab. *ImageNet Large Scale Visual Recognition Challenge (ILSVRC)*. URL: <http://www.image-net.org/challenges/LSVRC/>. dostęp: 30.08.2020.
- [5] DeepMind. *AlphaGo*. URL: <https://deepmind.com/research/case-studies/alphago-the-story-so-far>. dostęp: 30.08.2020.
- [6] Josh Bongard Rolf Pfeifer. *How the Body Shapes the Way We Think: a New View of Intelligence*. 2007.
- [7] John Stewart. „Cognition without neurons: Adaptation, learning and memory in the immune system.” W: (1993).
- [8] Janusz Starzyk. „Motivation in Embodied Intelligence”. W: (2008).
- [9] M. Csikszentmihalyi i M. Csikszentmihalyi. *Creativity: Flow and the Psychology of Discovery and Invention*. Harper Perennial Modern Classics. HarperCollinsPublishers, 1996. ISBN: 9780060171339.
- [10] Paweł Raif Ah-Hwee Tan Janusz Starzyk James Graham. „Motivated Learning for the Development of Autonomous Systems”. W: (2012). DOI: <https://doi.org/10.1016/j.cogsys.2010.12.009>.
- [11] Janusz Starzyk. „Motivated Learning for Computational Intelligence”. W: (2011). DOI: https://www.researchgate.net/publication/267375356_Motivated_Learning_for_Computational_Intelligence.